HW1: 从零开始构建三层神经网络分类器 —— EuroSAT 地表覆盖图像分类

空间智能课程

2026年4月

1. 任务概述

本次作业要求手工搭建三层神经网络（MLP）分类器，在遥感图像数据集 EuroSAT 上进行训练，实现基于卫星图像的土地覆盖分类。EuroSAT 数据集包含 10 个类别：AnnualCrop（一年生作物）、Forest（森林）、HerbaceousVegetation（草本植被）、Highway（高速公路）、Industrial（工业区）、Pasture（牧场）、PermanentCrop（多年生作物）、Residential（住宅区）、River（河流）、SeaLake（海域/湖泊）。

所有代码均使用 NumPy 实现，不依赖 PyTorch、TensorFlow 等自动微分框架，自主实现了前向传播、反向传播、优化器及损失函数。

2. 数据集与预处理

2.1 数据集概况

EuroSAT_RGB 数据集共包含 27,000 张 64×64 像素的 RGB 卫星遥感图像，分布在 10 个类别中，各类别样本数如下：

类别	样本数	类别	样本数
AnnualCrop	3,000	Industrial	2,500
Forest	3,000	Pasture	2,000
HerbaceousVegetation	3,000	PermanentCrop	2,500
Highway	2,500	Residential	3,000

类别	样本数	类别	样本数
River	2,500	SeaLake	3,000

2.2 预处理流程

1. 图像加载与尺寸统一：使用 PIL 加载 RGB 图像，统一 resize 至 64×64。
2. 归一化：将像素值从 [0, 255] 归一化至 [0, 1]。
3. 展平：将每张 64×64×3 的图像展平为 12,288 维向量，作为 MLP 输入。
4. 数据划分：按 80%/10%/10% 的比例划分为训练集（21,600）、验证集（2,700）和测试集（2,700），使用分层抽样（stratify）确保各类别比例一致。

3. 模型结构

3.1 三层 **MLP** 架构

模型采用经典的三层全连接网络：

```
Input (12288) → FC1 (12288→hidden_dim) → Activation1 → FC2 (hidden_dim→hidden_dim) → Activation2 → FC3 (hidden_dim→10) → Softmax
```

- **FC1**：将 12,288 维输入映射到隐藏层维度
- **FC2**：隐藏层到隐藏层的变换
- **FC3**：将隐藏层映射到 10 个类别的输出
- 激活函数：支持 ReLU、Sigmoid、Tanh 三种选择
- 权重初始化：采用 He 初始化（`W ~ N(0, sqrt(2/in_features))`），偏置初始化为 0

3.2 自主实现的关键组件

3.2.1 线性层（**Linear**）

前向传播：`y = x @ W + b`

反向传播：- `dW = x.T @ dout` - `db = sum(dout, axis=0)` - `dx = dout @ W.T`

3.2.2 激活函数

- **ReLU**：`y = max(0, x)`，反向传播 `dx = dout * (x > 0)`
- **Sigmoid**：`y = 1/(1+exp(-x))`，反向传播 `dx = dout * y * (1-y)`
- **Tanh**：`y = tanh(x)`，反向传播 `dx = dout * (1 - y^2)`

3.2.3 Softmax 交叉熵损失

为数值稳定性，先对 scores 减去最大值再做 softmax：

```
 shifted = scores - max(scores, axis=1)
probs = exp(shifted) / sum(exp(shifted), axis=1)
loss = -mean(log(probs[labels]))
```

反向传播梯度：`dout = (probs - one_hot(labels)) / N`

3.2.4 L2 正则化

在损失函数中加入权重衰减项：

```
 L2_loss = 0.5 * λ * (||W1||^2 + ||W2||^2 + ||W3||^2)
```

反向传播时对 dW 加入 `λ * W` 的梯度。

3.3 优化器

实现了带动量的 SGD 优化器：

```
 v = momentum * v + dW
W = W - lr * v
```

学习率衰减采用指数衰减策略：`lr = lr_init * exp(-decay * epoch)`

4. 训练配置与实验结果

4.1 最佳模型训练

通过超参数搜索（详见第 5 节），确定最佳配置为：

- 隐藏层维度：512
- 激活函数：Tanh
- 学习率：0.01

- L2 正则化强度：0.0
- 批大小：256
- 训练轮数：30
- 动量：0.9

4.2 训练过程

训练过程中训练集损失、验证集损失和验证集准确率的变化曲线如下：

训练曲线

从训练曲线可以观察到：

1. 训练损失从 1.81 持续下降至 0.99，说明模型在训练集上持续学习。
2. 验证损失从 1.54 下降至 1.06 左右后趋于平稳，训练损失和验证损失之间的差距逐渐增大，表明模型开始出现一定程度的过拟合。
3. 验证集准确率从 43.9% 逐步提升至 64.1%（最佳），在第 19 轮达到最高后有小幅波动。

4.3 测试集结果

最佳模型在独立测试集上的表现为：

- 总体准确率：63.78%

各类别的详细分类报告：

类别	Precision	Recall	F1-Score	Support
AnnualCrop	0.5497	0.6633	0.6012	300
Forest	0.8106	0.8700	0.8392	300
HerbaceousVegetation	0.4590	0.5967	0.5188	300

类别	Precision	Recall	F1-Score	Support
Highway	0.4757	0.1960	0.2776	250
Industrial	0.7757	0.8440	0.8084	250
Pasture	0.6721	0.8300	0.7427	200
PermanentCrop	0.7282	0.3000	0.4249	250
Residential	0.5622	0.6933	0.6209	300
River	0.5905	0.5480	0.5685	250
SeaLake	0.7926	0.7900	0.7913	300

表现较好的类别：Forest（F1=0.84）、Industrial（F1=0.81）、SeaLake（F1=0.79）、Pasture（F1=0.74）——这些类别在视觉特征上有较强的区分性（森林的绿色纹理、工业区的灰色建筑、水域的蓝色/深色）。

表现较差的类别：Highway（F1=0.28）、PermanentCrop（F1=0.42）——这些类别与其他类别存在较多视觉相似性，误分类严重。

4.4 混淆矩阵

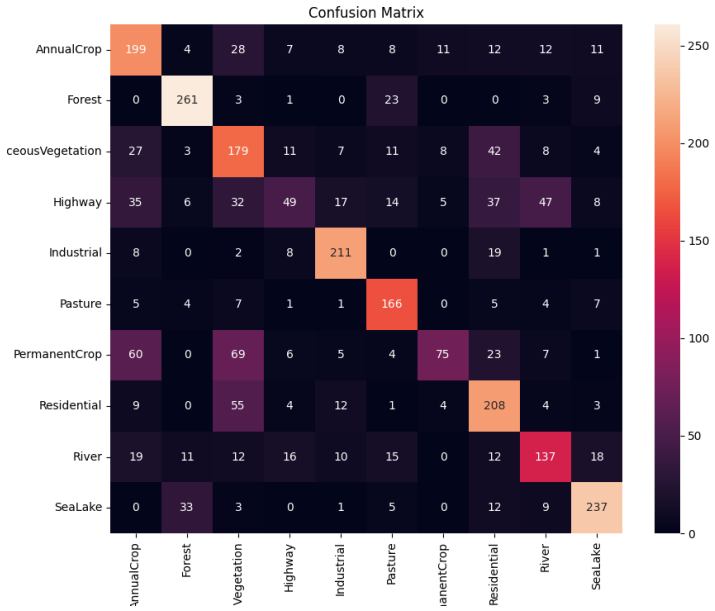

混淆矩阵

混淆矩阵清晰展示了各类别间的误分类模式，主要的误分类对将在第 7 节详细分析。

5. 超参数搜索

5.1 搜索空间

采用网格搜索，搜索空间如下：

超参数	搜索范围
隐藏层维度	{128, 256, 512}
学习率	{0.001, 0.01, 0.1}
L2 正则化强度	{0.0, 0.01}
激活函数	{relu, tanh}

共 36 种组合，每种配置训练 15 个 epoch 进行快速评估。

5.2 搜索结果

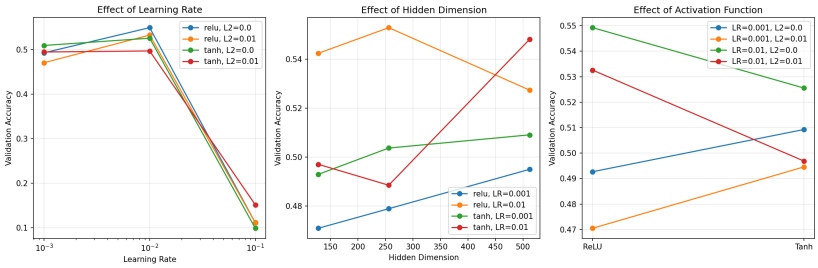

超参数对比

关键发现：

1. 学习率的影响最为显著：学习率为 0.1 时，所有配置的验证准确率均降至 ~10%（随机猜测水平），说明学习率过大导致训练发散；学习率为 0.001 时收敛较慢，15 epoch 内准确率仅 47-53%；学习率为 0.01 时效果最佳，达到 46-60%。

2. 隐藏层维度：较大的隐藏维度（512）通常带来更好的性能，因为模型容量更大，能学习更复杂的特征。但差异不如学习率显著。

3. 激活函数：在本次实验中，Tanh 在部分配置下优于 ReLU（尤其是 hidden_dim=512, lr=0.01 的最佳配置）。这可能是因为 Tanh 的零中心输出有助于后续层的优化。

4. **L2** 正则化：在本实验中，L2 正则化（λ=0.01）反而降低了性能，可能是因为 15 epoch 的训练尚不足以出现过拟合，正则化反而限制了模型学习。

5.3 Top-5 最佳配置

排名	Hidden Dim	LR	L2	Activation	Val Acc
1	512	0.01	0.0	tanh	60.30%
2	256	0.01	0.01	relu	56.52%
3	512	0.01	0.0	relu	55.52%
4	128	0.01	0.0	relu	55.19%
5	256	0.01	0.0	relu	54.07%

6. 权重可视化与空间模式分析

6.1 第一层权重可视化

将训练好的模型第一层（FC1）的权重矩阵中前 16 个神经元的权重，恢复为 64×64×3 的图像进行可视化：

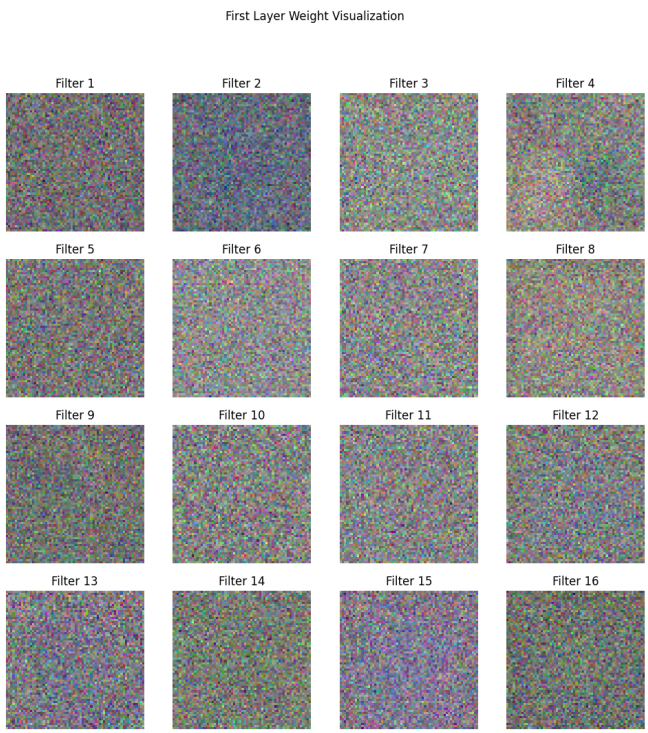

权重可视化

6.2 空间模式观察

从权重可视化中可以观察到以下模式：

1. 颜色模式：部分滤波器呈现出明显的色彩倾向。例如，某些滤波器在绿色通道上响应强烈（可能与 Forest、HerbaceousVegetation、Pasture 类别相关），某些在蓝色通道上响应较强（可能与 River、SeaLake 相关），还有部分在灰色/棕色通道上响应（可能与 Highway、Industrial 相关）。

2. 空间纹理：部分权重呈现出类似 Gabor 滤波器的条纹状模式，暗示网络在第一层学习到了检测边缘和方向性纹理的特征，这对于区分 Highway（线性结构）和 River（曲线结构）等类别可能有用。

3. 局部 **vs** 全局：大多数权重呈现局部化的高亮区域而非均匀分布，表明网络倾向于关注图像中的特定区域而非全局统计，这与人类视觉系统的局部感受野机制类似。

4. 多样性：不同滤波器呈现出不同的模式和颜色偏好，说明模型学习到了多样化的底层特征，这为后续层的组合特征提供了丰富的基础。

7. 错例分析

错例分析

7.1 主要误分类模式

从混淆矩阵和错例分析中，识别出以下主要误分类对及其可能原因：

(1) PermanentCrop → HerbaceousVegetation（69次）和 PermanentCrop → AnnualCrop（60次）

原因分析：多年生作物（如果园、葡萄园）在卫星图像中与草本植被和一年生作物在视觉上高度相似，均呈现绿色植被覆盖。三者主要区别在于植被的空间排列和纹理，但 64×64 的分辨率下这种差异很微弱，MLP 将图像展平后丢失了空间结构信息，使得区分更加困难。

(2) Highway → River（47次）

原因分析：高速公路和河流在卫星图像中均呈现为细长的带状结构，且都可能被两侧的植被包围。从上方俯瞰时，深色的高速公路与深色的河流在颜色上也非常接近。这是本次实验中最具代表性的“视觉相似性”导致的误分类案例。

(3) Residential → HerbaceousVegetation（55次）

原因分析：住宅区通常包含大量绿化带、花园和树木，在低分辨率卫星图像中，这些绿色区域可能占据相当大的比例，使得住宅区整体色调偏绿，与草本植被混淆。

(4) Highway → Residential（37次）和 Highway → AnnualCrop（35次）

原因分析：高速公路周围通常有建筑物和绿化带，且高速公路本身的灰色表面与住宅区屋顶颜色相近。同时，高速公路穿过农田区域时，其与周围作物的边界在高分辨率下也不够清晰。

(5) SeaLake → Forest（33次）

原因分析：部分湖泊周围被密林环绕，在 64×64 低分辨率下，水域与周围森林的边界模糊，可能导致模型倾向于将深色区域整体判为森林。

7.2 MLP 的局限性

通过错例分析，可以总结 MLP 在该任务上的主要局限：

1. 空间信息丢失：MLP 将 64×64×3 图像展平为 12,288 维向量，完全丢失了像素间的空间关系（如相邻性、方向性），而很多类别的关键区分特征恰恰是空间结构（如 Highway 和 River 的带状结构）。
2. 参数量过大：输入维度高达 12,288，第一层权重矩阵参数量极大（12,288×512 ≈ 630万），容易过拟合且训练效率低。
3. 缺乏平移不变性：MLP 不具备卷积网络的平移不变性，同类别的不同位置出现的相同纹理无法被有效识别。

这些局限说明，对于图像分类任务，卷积神经网络（CNN）等保留空间结构的架构会有更好的表现。

8. 总结

本实验从零实现了一个三层 MLP 分类器，在 EuroSAT 遥感图像数据集上取得了 63.78% 的测试准确率。主要贡献和发现包括：

1. 自主实现：完全使用 NumPy 实现了前向传播、反向传播、SGD 优化器（含动量）、交叉熵损失、L2 正则化和学习率衰减，未依赖任何深度学习框架。

2. 超参数搜索：通过网格搜索发现学习率是最关键的超参数，0.01 为最优值；较大隐藏维度和 Tanh 激活函数组合效果最佳。

3. 权重可视化：第一层权重呈现出有意义的颜色和纹理模式，表明模型学习到了与地物特征相关的底层视觉特征。

4. 错例分析：主要误分类源于类别间的视觉相似性（如 Highway 与 River、PermanentCrop 与 HerbaceousVegetation）以及 MLP 丢失空间结构信息的固有局限。

5. 改进方向：采用 CNN 架构保留空间信息、增加图像分辨率、使用数据增强等策略有望显著提升分类性能。

附录：代码结构

```
src/
├── data_loader.py        # 数据加载与预处理
├── layers.py             # 线性层、激活函数、Softmax交叉熵损失
├── model.py              # 三层MLP模型定义
├── optimizer.py          # SGD优化器（含动量和学习率衰减）
├── train.py              # 训练脚本
├── test.py               # 测试脚本
├── hyperparam_search.py  # 超参数网格搜索
└── utils.py              # 可视化工具函数
```